

MÉTHODES D'ÉVALUATION


HUMAN SYSTEMS INTEGRATION COURSE

CHLOÉ MOREL – ERGONOME IHM



RAPPEL


HSI AS AN INTERSECTION OF HFE, SE, AND CS




CONCEPTION CENTRÉE UTILISATEURS

Cycle de conception itératif des systèmes interactifs

« *Tout système conçu pour être utilisé par des gens devrait être facile à apprendre et à se remémorer, être utile, c'est-à-dire comporter des fonctions dont les gens ont vraiment besoin dans leur travail, et être facile et agréable à utiliser* » (Gould et Lewis, 1985)



(Lallemand et Gronier, 2018)



CONCEPTION CENTRÉE UTILISATEUR


CRITÈRES DE QUALITÉ D'USAGE

L'utilisabilité est : le degré selon lequel un produit peut être utilisé par des utilisateurs identifiés pour atteindre des buts définis, avec efficacité, efficience et satisfaction, dans un contexte d'utilisation spécifié.

Norme ISO 9241-11 (1998)

⇒ Deux critères de performance et un critère de ressenti subjectif.

Satisfaction : l'absence d'inconfort, et les attitudes positives dans l'utilisation du produit.



Efficacité : la précision et le degré d'achèvement selon lesquels l'utilisateur atteint des objectifs spécifiés.


Efficience : le rapport entre les ressources dépensées et la précision et le degré d'achèvement selon lesquels l'utilisateur atteint des objectifs spécifiés.

CRITÈRES DE QUALITÉ D'USAGE

L'expérience utilisateur (UX) correspond aux "perceptions et réactions d'une personne qui résultent de l'utilisation effective et/ou anticipée d'un produit, système ou service"

(Norme ISO 9241-210, 2010)

L'expérience utilisateur : inclut toutes les émotions, convictions, préférences, perceptions, réactions physiques et psychologiques, comportements et réalisations de ce dernier qui interviennent avant, pendant et après utilisation.






TESTS UTILISATEURS

TEST UTILISATEUR : DÉFINITION

"La méthode du test utilisateur consiste à évaluer l'UX d'un système en observant la façon dont les utilisateurs cibles l'utilisent pour réaliser des tâches. Elle est aussi une combinaison flexible de méthodes quantitatives et qualitatives permettant d'évaluer la performance des participants, leurs comportements ou encore leurs réactions."

(Lallemand, C., & Gronier, G. ,2015).




TEST UTILISATEUR : POURQUOI CETTE MÉTHODE ?

La méthode du test utilisateur s'inscrit dans un processus itératif qui peut s'appliquer tour à tour à toutes les phases de conception d'un système :




SYNOPTIQUE D'UN TEST UTILISATEUR




RECRUTEMENT

Trouver des utilisateurs dans la cible

- Combien d'utilisateurs pour obtenir des résultats valides ?
- Nielsen (2000), Why You Only Need to Test With 5 Users



DÉROULEMENT D'UN TEST



PHASE PRÉ-TEST

Réalisation d'une simulation du test avec une personne volontaire (exemple : collègue).

Vérification :

- ✓ Du matériel
- ✓ De la qualité des données obtenues (vidéo, son enregistrés)
- ✓ Compréhension des scénarios
- ✓ Compréhension des entretiens
- ✓ Vérification du temps du test
- ✓ Du produit testé (produit réel/prototype/maquette)

ENTRETIEN PRÉ-TEST

Entretien semi-dirigé : Questions ouvertes et fermées

- Pour découvrir la personne (sur son activité etc...)

Quel est votre profession ?

Pouvez-vous me décrire votre activité professionnelle ?

- En lien avec le produit testé
- Terminer par question ouverte : Avez-vous des remarques dont vous souhaitez me faire part ?

Rôle de l'ergonome : Relancer + rester neutre

PHASE DE PASSATION

Exemple : Expérimentation avec des pilotes de chasse : briefing de mission



❑ **OBJECTIF n°1** : dans le cadre de l'opération **BLACK TOMAHAWK**, détruire une capacité de communication militaire dans la zone « **BELOVED** » 045°/60Nm Bulls

- 2*Command Post

❑ **OBJECTIF n°2** : dans le cadre de l'opération **RED IROQUOIS**, engager les cibles émergentes dans la zone périscopière « **LYKOS 1** » 300°/20 Nm Bulls.

- Main Battle Tanks
- Arty elements
- Personnel in OPen

❑ **RISK LEVEL :**

- Opération **BLACK TOMAHAWK** : **RISK LEVEL LOW**
 - Eviter l'exposition à l'ennemi sans supériorité avérée
 - Ne pas rentrer dans les zones d'engagement des systèmes de défense aérienne adverse
- Opération **RED IROQUOIS** : **RISK LEVEL MEDIUM**
 - **La survie est plus importante que la mission** : limiter l'entrée dans les domaines de tir adverses et minimiser le temps d'exposition à la menace

ENTRETIEN DEBRIEFING

Entretien semi-dirigé : Questions ouvertes

- Approfondir le ressenti du participant face au produit testé
Avant de revenir en détail sur ce que vous avez vu qu'en avez-vous pensé ?
quel est votre impression générale sur le produit que nous venons de découvrir ensemble ?
- Revenir sur les scénarii réalisés (ex : questions par fonctionnalité)
- Suggestions d'amélioration
Avez-vous des suggestions d'amélioration à nous faire ?
- Terminer par des questions ouvertes :
Si vous pouviez changer une chose, de quoi s'agirait-il ?
Voyez-vous d'autres choses à ajouter ?

ANALYSE

Le recueil des données porte le plus souvent sur deux critères :

- Les performances
- La satisfaction et l'UX

Pour la passation, différents types de métriques de performance quantitatifs peuvent être analysés :

- Proportion de succès et d'échecs pour chaque scénario
- Nombre d'erreurs commises pour chaque scénario
- Nombre et type d'erreurs répétées
- Nombre d'actions effectuées par rapport au nombre d'actions minimal requis pour réaliser la tâche
- Le temps moyen mis pour la réalisation de chaque scénario
- Les scores aux questionnaires ...

ANALYSE

Analyse qualitative pour analyser la performance

- Du contenu des verbalisations des utilisateurs
 - Du contenu des entretiens avant test et au cours du débriefing
- ⇒ compter les problèmes que rapportent les utilisateurs ou compter la fréquence des utilisateurs qui rencontrent tel ou tel problème
- ⇒ Ajouter une criticité aux problèmes rencontrés par les participants (bloquant, critique, medium, mineur)
- ⇒ Relever les suggestions d'amélioration

ANALYSE

Dans les critères de l'UX (vision plus globale et émotionnelle des interactions Homme-Machine) :

- L'appréciation esthétique
- La confiance
- L'utilité perçue
- L'amusement
- La facilité de navigation, etc.

Besoin d'analyser :

- Le contenu des verbalisations des utilisateurs
- Le contenu des entretiens avant test et au cours du débriefing
- Utilisation d'outils spécifiques (Ex : face reader, eye tracking...)



LES OUTILS POUR L'ANALYSE DU COMPORTEMENT

EYE TRACKING : TOBII

Eyetracking consiste « à suivre et enregistrer en continu et en temps réel, la position du regard, de l'utilisateur de l'écran » (Nielsen et Permyer, 2010)

Capture des mouvements oculaires par enregistrement des points de fixation et des saccades des regards de l'utilisateur.





THE OBSERVER XT: NOLDUS

The Observer XT pour l'encodage et l'analyse des comportements utilisateurs. <http://www.noldus.com/office/fr/observer-xt>

Avantage en ergonomie :

- Pour compléter les tests utilisateurs et objectiver ses résultats.
- Permet d'instrumenter l'observation des usages.
- Représente les comportements de manière précise et quantitative
- Intègre les données comportementales et physiologiques
- Permet de réaliser des analyses statistiques
- Crée des clips vidéo des données les plus intéressantes
- Importation de données provenant de différentes sources



FACE READER : NOLDUS

Face Reader est un système automatisé pour la reconnaissance des expressions faciales, permettant aux utilisateurs une évaluation objective de l'émotion des sujets.

<http://www.noldus.com/office/fr/facereader>


Les six émotions de base sont analysées :

- Surprise
- Joie
- Peur
- Tristesse
- Dégoût
- Colère
- Et: Neutre, mépris

Avantages en ergonomie :

- Compléter les tests utilisateurs
- Modèles pour différents groupes ethniques, personnes âgées et enfant inclus
- Calibration en fonction du sujet
- Compatible avec the Observer XT





CAPTIV : TEA

CAPTIV est un logiciel développé par TEA (Technologie Ergonomie Applications) et l'INRS permettant l'acquisition **de données** destiné à synchroniser des images vidéo avec des observations visuelles et des mesures issues de différents capteurs.

Avantages en ergonomie :

- Permet de relier dans le détail des mesures physiques à l'activité d'un sujet.
- Très utilisé pour faire de l'analyse des postes de travail et étudier l'astreintes* physiologiques (fréquence cardiaque, les mouvements corporels, EMG, conductivité électrodermale, mesure angulaire, températures corporelles, mouvement oculaire, etc...).
- Utilisation dans des domaines divers : santé/ prévention des risques professionnels par l'analyse des postes de travail, jeu vidéo, sport, etc...
- Pour compléter les tests utilisateurs et objectiver ses résultats.

** Réactions physiologiques et psychologiques aux actions des contraintes (facteur de charge agissant sur l'homme au travail).*

ECG : ELECTROCARDIOGRAPHIE


- Représentation graphique de l'activité électrique du cœur
- Module à transmission sans fil pour la mesure du signal ECG brut : signal électrique détecté de l'ordre du millivolt
- Réduction Artefact

≠ cardiofréquencemètre (mesure la fréquence cardiaque instantanée en BPM)



EMG : ELECTROMYOGRAPHIE

- Représentation graphique de l'activité électrique du muscle
- Calcul du RMS (Root-mean-square) : lissage du signal



GSR : ACTIVITÉ ÉLECTRODERMALE

- Envoi d'un courant électrique
- Mesure de la tension
- Variation de la tension en fonction de la résistance $U = R \cdot I$
- Résistance ↗ Conductance ↘ Sudation ↗
- Analyse du stress et de l'effort



*ET BIEN
D'AUTRES ...*

INGESCAPE CIRCLE

- Ingescape, une plateforme pour l'intégration homme-système
- Ingescape Circle est un environnement intuitif permettant aux développeurs et non-développeurs de travailler ensemble de manière collaborative et constructive, en utilisant les meilleures pratiques en matière de méthodologies agiles, itératives et créatives dans les projets logiciels, les jumeaux numériques et les simulations.



ECHELLES STANDARDISÉES

ECHELLES STANDARDISÉES

Objectifs

- Comparer plusieurs versions d'un même système (cycles de conception itératif);
- Comparer différents systèmes entre eux;
- Tester un système auprès de plusieurs catégories d'utilisateurs (experts, inexperts etc.);
- Obtenir des données quantitatives.

Validation scientifique

- **Fiabilité** (ou fidélité) : l'échelle, appliquée dans les mêmes conditions doit permettre d'obtenir les mêmes résultats.
- **Validité** : L'échelle évalue l'opinion des utilisateurs définie par l'échelle (utilisabilité, UX etc...)



SUS (SYSTEM USABILITY SCALE) POUR MESURER L'UTILISABILITÉ (BROOKES, 1986)

“L'utilisabilité est le degré selon lequel un produit peut être utilisé par des utilisateurs identifiés pour atteindre des buts définis, avec efficacité, efficience et satisfaction, dans un contexte d'utilisation spécifié.”

Norme ISO 9241-11 (1998)

System Usability Scale

© Digital Equipment Corporation, 1986.

	Strongly disagree				Strongly agree
1. I think that I would like to use this system frequently	☐	☐	☐	☐	☐
	1	2	3	4	5
2. I found the system unnecessarily complex	☐	☐	☐	☐	☐
	1	2	3	4	5
3. I thought the system was easy to use	☐	☐	☐	☐	☐
	1	2	3	4	5
4. I think that I would need the support of a technical person to be able to use this system	☐	☐	☐	☐	☐
	1	2	3	4	5
5. I found the various functions in this system were well integrated	☐	☐	☐	☐	☐
	1	2	3	4	5
6. I thought there was too much inconsistency in this system	☐	☐	☐	☐	☐
	1	2	3	4	5
7. I would imagine that most people would learn to use this system very quickly	☐	☐	☐	☐	☐
	1	2	3	4	5
8. I found the system very cumbersome to use	☐	☐	☐	☐	☐
	1	2	3	4	5
9. I felt very confident using the system	☐	☐	☐	☐	☐
	1	2	3	4	5
10. I needed to learn a lot of things before I could get going with this system	☐	☐	☐	☐	☐
	1	2	3	4	5

NASA-TLX (TASK LOAD INDEX, INDICE DE CHARGE DE TRAVAIL MENTAL) POUR MESURER LA CHARGE DE TÂCHE SUBJECTIVE (HART & STAVELAND, 1988).

Regroupe 6 items sur une échelle de 20 graduations de 5 points :

- Exigence mentale (valence négative)
- Exigence physique (valence négative)
- Pression temporelle (valence négative)
- Performance (valence positive)
- Effort (valence négative)
- Frustration (valence négative)

NASA Task Load Index

Hart and Staveland's NASA Task Load Index (TLX) method assesses work load on five 7-point scales. Increments of high, medium and low estimates for each point result in 21 gradations on the scales.

Name	Task	Date
------	------	------

Mental Demand

How mentally demanding was the task?

Very Low
Very High

Physical Demand

How physically demanding was the task?

Very Low
Very High

Temporal Demand

How hurried or rushed was the pace of the task?

Very Low
Very High

Performance

How successful were you in accomplishing what you were asked to do?

Perfect
Failure

Effort

How hard did you have to work to accomplish your level of performance?

Very Low
Very High

Frustration

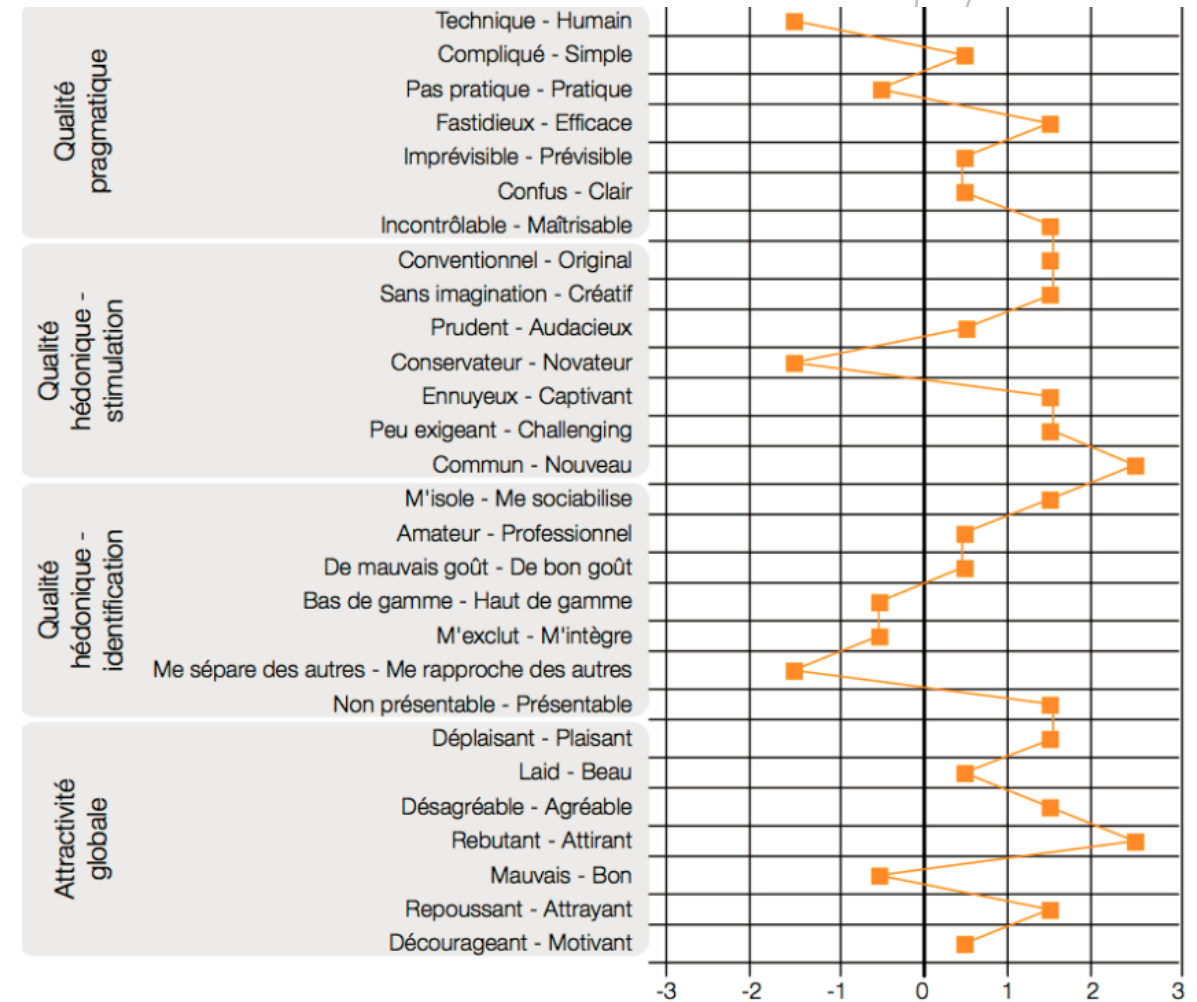
How insecure, discouraged, irritated, stressed, and annoyed were you?

Very Low
Very High

ATTRACK-DIFF

Une échelle d'évaluation de l'UX en 28 questions
(Hassenzahl, M., 2003):


- Echelle de qualité pragmatique (QP) : décrit l'utilisabilité du produit et indique à quel point le produit permet aux utilisateurs d'atteindre leur(s) but(s) (7 items)
- Echelle de qualité hédonique – stimulation (QH-S) : indique dans quelle mesure le produit peut soutenir le besoin de stimulation (7 items)
- Echelle de qualité hédonique – identification (QH-I) : indique dans quelle mesure le produit permet à l'utilisateur de s'identifier à lui (7 items)
- Echelle d'attractivité globale (ATT) : décrit la valeur globale du produit basée sur la perception des qualités pragmatiques et hédoniques (7 items)




SAM (*SELF-ASSESSMENT MANIKIN*): *ECHELLE DE RECUEIL DES ÉMOTIONS* (BRADLEY & LANG, 1994 ; GIL, 2009)

L'échelle présente trois dimensions : *plaisir*, *éveil émotionnel* et *dominance* représentées par 3 séries de mannequins. La première ligne correspond à la dimension de plaisir. Si le sujet est dans un état positif extrême, il doit cocher une croix sur le mannequin le plus à gauche, sinon il doit sélectionner celui qui est le plus à droite. Cependant, le sujet peut choisir de sélectionner les mannequins intermédiaires. Il doit appliquer les mêmes principes pour les dimensions d'éveil émotionnel (très éveillé/excité pour le mannequin de gauche ; très calme pour le mannequin de droite) et de dominance (très soumis pour le mannequin de gauche ; très dominant pour le mannequin de droite).


Déplaisir / Plaisir



Endormi / Excité






Contrôlé par la situation / Contrôlant la situation



*ET BIEN
D'AUTRES ...*

OUTILS DE PROTOTYPAGE



ADOBE XD, FIGMA, AXURE, BALSAMIQ, ETC...



EVALUATION EXPERTE

EVALUATION EXPERTE

« L'évaluation experte, aussi appelée « évaluation heuristique » ou « inspection ergonomique », est une évaluation de la conformité d'une interface en regard de principes ergonomiques de base (ou principes d'utilisabilité), que l'on appelle des critères ergonomiques ou « heuristiques ». (Millerand, F., & Martial, O. (2001))

L'ÉVALUATION EXPERTE

L'évaluation experte par les critères :

- Constitue la première étape d'une intervention en ergonomie des Interfaces Homme-Machine.
- Permet de repérer les défauts d'utilisabilité potentiels d'une IHM sans impliquer les utilisateurs.
- Permet d'éviter les pièges de la subjectivité et des goûts personnels en donnant un cadre de travail objectif.
- Méthode précise et adaptable, formelle et réutilisable.
- Doit être réalisée après une prise de connaissance de l'usage en situation du système à évaluer.
- Doit être idéalement réalisée par plus d'un évaluateur.

LES CRITÈRES DE BASTIEN ET SCAPIN

Qui sont Bastien et Scapin ?

- Deux chercheurs français qui ont procédé à partir de 1997 à la synthèse de 900 recommandations dans le domaine de l'ergonomie informatique.
- Leur travail a abouti à une liste de 18 critères répartis en 8 critères principaux.

Pourquoi les utiliser ?

- rapide et peu coûteux
- Mesures précises
- Pour préparer des tests utilisateurs et identifier en amont les problèmes
- Peut servir comme base de travail
- Relever les points positifs de l'interface

8 CRITÈRES PRINCIPAUX

1

Guidage

2

Charge de travail

3

Contrôle explicite

4

Adaptabilité

5

Gestion des erreurs

6

Homogénéité /
Cohérence

7

Signifiante des codes et
Dénominations

8

Compatibilité

SOUS-CRITÈRES

1. Guidage

- 1.1. Incitation
- 1.2. Groupement / Distinction entre Items
 - 1.2.1. Groupement / Distinction par la localisation
 - 1.2.2. Groupement / Distinction par le format
- 1.3. Feedback Immédiat
- 1.4. Lisibilité

2. Charge de Travail

- 2.1. Brièveté
 - 2.1.1. Concision
 - 2.1.2. Actions Minimales
- 2.2. Densité Informationnelle

3. Contrôle Explicite

- 3.1. Actions Explicites
- 3.2. Contrôle Utilisateur

4. Adaptabilité

- 4.1. Flexibilité
- 4.2. Prise en compte de l'expérience de l'utilisateur

5. Gestion des Erreurs

- 5.1. Protection contre les Erreurs
- 5.2. Qualité des Messages d'Erreurs
- 5.3. Correction des Erreurs

6. Homogénéité / Cohérence

7. Signifiante des Codes et Dénominations

8. Compatibilité

COMMENT UTILISEZ LES CRITÈRES ?

- L'évaluateur doit parcourir l'interface plusieurs fois en inspectant les éléments d'interaction et en les confrontant aux 8 critères et à leurs sous-critères.
- Chaque problème identifié est ensuite évalué en fonction de son niveau de gravité.
- Exemple d'un tableau de synthèse d'un rapport d'évaluation experte avec les critères de Bastien et Scapin :

N°	Problème relevé	Description	Critère de Bastien et Scapin associé	Priorité	Recommandation
1	Gestion des erreurs	Si l'un des champs du formulaire est mal renseigné, l'appui sur le bouton validation n'aura aucun effet.	Gestion des erreurs	Elevée	Indiquer à l'utilisateur quelles sont les erreurs qui bloquent la validation du formulaire et comment les corriger.

*MERCI POUR
VOTRE
ATTENTION !*

Références :

- Lallemand, C., & Gronier, G. (2016). Méthodes de design UX: Eyrolles. 30 méthodes fondamentales pour concevoir et évaluer les systèmes interactifs. Paris, Eyrolles.
- Daumal, S. (2015). Design d'expérience utilisateur: principes et méthodes UX. Editions Eyrolles.
- Baccino, T., Bellino, C., & Colombi, T. (2005). Mesure de l'utilisabilité des interfaces. Hermès Science-Lavoisier, 1-250.
- Albert, W., & Tullis, T. (2013). Measuring the user experience: collecting, analyzing, and presenting usability metrics. Newnes.
- Bastien, J.M.C., Scapin, D. (1993). Ergonomic Criteria for the Evaluation of
- Human-Computer interfaces. *Institut National de Recherche en Informatique et en Automatique*, France.
- Scapin, D. L., & Bastien, J. C. (1996). *Inspection d'interfaces et critères ergonomiques* (Doctoral dissertation, INRIA).
- Bastien, J.M.C., Leulier, C., & Scapin, D.L. (1998). L'ergonomie des sites web.
- J.-C. Le Moal & B. Hidoine (Eds.), *Créer et maintenir un service Web* (pp. 111-173). Paris
- Millerand, F., & Martial, O. (2001). Guide pratique de conception et d'évaluation ergonomique de sites Web. *Centre de Recherche Informatique de Montréal*.

*QUELLES
MÉTHODES/OUTILS
POURRIEZ-VOUS
METTRE EN PLACE
POUR VOTRE
PROJET?*